

Laboration 1

Från data till möjligheter

Under föreläsningen pratade vi om att innovation ofta börjar med ett problem. För att kunna förstå problem behöver vi ofta data.

Idag ska vi därför börja arbeta med riktiga dataset.

Målet med laborationen är inte att ni ska bli experter på Python idag, utan det är att ni ska lära er hur man:

- läser in data,
- undersöker vad data innehåller,
- visualiserar data,
- hittar mönster, och
- funderar på hur data kan användas för att skapa värde.

När dataanalytiker öppnar ett nytt dataset börjar de sällan med att försöka besvara en fråga direkt.

I stället börjar de med att utforska datasetet och ställa frågor som:

- Vad innehåller datasetet?
- Vad verkar mätas?
- Finns det några tydliga mönster?
- Vem skulle kunna ha nytta av informationen?

Det är precis det ni ska få göra idag.

Vad är en CSV-fil?

De flesta dataset vi kommer att arbeta med är sparade som CSV-filer. CSV står för *Comma Separated Values*.

Man kan tänka på en CSV-fil som ett kalkylblad där:

- varje rad är en observation, och
- varje kolumn är en variabel.

Exempel

I tabellen nedan är datum, temperatur och nederbörd varsin variabel:

Tabell: Ett exempel på mätvärden.

Datum	Temperatur [$^{\circ}\text{C}$]	Nederbörd [mm]
2024-01-01	5,2	12
2024-01-02	6,1	8
2024-01-03	3,8	15

Varje rad beskriver ett specifikt tillfälle då mätningen gjordes.

Läsa in data i Python

För att läsa in data använder vi biblioteket pandas, vilket är ett av de vanligaste biblioteken för dataanalys i Python.

Innan vi börjar använda pandas måste vi importera det, vilket vi gör genom:

```
import pandas as pd
```

Läsa in data i Python

Nu kan vi läsa in själva filen, vilket vi gör genom:

```
df = pd.read_csv("filnamn.csv")
```

Här gäller att:

- `pd` är en förkortning för `pandas`,
- `read_csv()` läser in filen, och
- `df` står för `dataframe`.

Vad innehåller ett dataset?

När vi öppnar ett nytt dataset vill vi först förstå vad det innehåller. Den första frågan vi ska ställa är därför: **Vad innehåller datasetet?**

Vi börjar således med:

```
df.head(n)
```

Detta visar alla rader till och med rad n .

Vad innehåller ett dataset?

Några frågor jag vill att ni funderar på är nu:

- Vilka variabler finns?
- Vad verkar de beskriva?
- Vilken information verkar datasetet innehålla?

Storleken av dataset

Vi kan också undersöka storleken av datasetet genom:

```
df.shape
```

Detta ger storleken av datasetet på formen (rader, kolumner), exkluderat första raden med alla variabler.

Några frågor jag vill att ni funderar på är nu:

- Hur många rader finns?
- Hur många kolumner finns?

Vi kan även få en statistisk översikt av datasetet genom:

```
df.describe()
```

Detta ger bland annat:

- medelvärde,
- minsta värde,
- största värde, och
- standardavvikelse.

Övning del 1

Dags att lösa lite uppgifter!

Enklare statistiska beräkningar

Under föreläsningen pratade vi om medelvärde, median och spridning. Nu ska vi beräkna dessa på riktig data med pandas.

Vi börjar med medelvärde (*mean* på engelska). Detta görs genom:

```
df["variabelnamn"].mean()
```

Enklare statistiska beräkningar

På liknande sätt kan vi beräkna medianen, det största värdet, det minsta värdet och standardavvikelsen genom:

```
df["variabelnamn"].median()
```

```
df["variabelnamn"].max()
```

```
df["variabelnamn"].min()
```

```
df["variabelnamn"].std()
```

Standardavvikelser

Notera att om man skriver:

```
df["variabelnamn"].std()
```

så får man standardavvikelsen för ett stickprov. Vill man i stället ha för en population ska man skriva:

```
df["variabelnamn"].std(ddof=0)
```

Här står ddof för *delta degrees of freedom*. Det vi dividerar vår summa med för att beräkna standardavvikelser är $n - \text{ddof}$.

Dags att lösa lite uppgifter!

Människor är ofta bättre på att tolka bilder än tabeller. Därför visualiserar vi data.

Innan vi kan skapa grafer behöver vi dock importera Matplotlib. Detta görs genom:

```
import matplotlib.pyplot as plt
```

Linjediagram

Linjediagram används för att studera förändringar över tid. Dessa skapas genom:

```
df.plot(x="variabel1", y="variabel2")
```

En fråga jag vill att ni funderar på nu är: **Ser ni någon trend?**

Histogram

Histogram visar hur värden är fördelade. Dessa skapas (med n intervall) genom:

```
df["variabelnamn"].hist(bins=n)
```

En fråga jag vill att ni funderar på nu är: **Vilka värden verkar vanligast?**

Spridningsdiagram

Spridningsdiagram (*scatter plots* på engelska) används för att undersöka samband mellan två numeriska variabler. Dessa skapas genom:

```
df.plot.scatter(x="variabel1", y="variabel2")
```

En fråga jag vill att ni funderar på nu är: **Verkar det finnas ett samband mellan variablerna?**

Viktigt för att visa själva graferna

För att graferna ska visas måste vi också ha med:

```
plt.show()
```

Dags att lösa lite uppgifter!

Dags att lösa lite uppgifter!

Idag har ni tagit första steget mot att arbeta med riktiga dataset.

Ni har inte bara analyserat data, utan ni har också börjat fundera på hur data kan användas för att förstå världen och skapa lösningar på riktiga problem.

Det är precis det som ligger i hjärtat av rymdinnovation.