

Övning del 1 – Datakvalitet

Ni har precis fått in miljödata från en satellit som övervakar vegetation, nederbörd och temperatur. Innan man kan använda datasetet måste någon kontrollera att den faktiskt går att lita på. Er uppgift är därför att genomföra en första kvalitetsgranskning av datasetet.

Använd **detta dataset** och besvara följande frågor:

1. Hur många rader innehåller datasetet?
2. Hur många kolumner finns?
3. Finns det några saknade värden?
4. I vilka variabler finns de?
5. Finns det några misstänkta outliers?
6. Vilka observationer skulle ni vilja undersöka närmare?

Övning del 2 – Filtrering

Efter den första granskningen vill man fokusera på specifika delar av datasetet. Genom att filtrera bort vissa observationer kan man ibland upptäcka mönster som annars är svåra att se.

Använd **detta dataset** för att skapa nya dataset som innehåller:

1. Endast åren 2015–2024.
2. Endast åren 2020–2024.
3. Endast observationer där NDVI är större än 0,7.

Fundera sedan över:

- Hur förändras datasetet?
- Ser några trender tydligare ut efter filtreringen?

Övning del 3 – Korrelation

Forskarna misstänker att temperatur, nederbörd och vegetation påverkar varandra, men stämmer det verkligen? Nu ska ni undersöka om det finns statistiska samband mellan olika variabler i datasetet. Kom ihåg att ett samband inte nödvändigtvis betyder att den ena variabeln orsakar den andra.

Använd **detta dataset** och undersök följande variabelpar:

1. Temperatur och NDVI.
2. Nederbörd och NDVI.

3. Temperatur och nederbörd.

För varje par ska ni:

- skapa ett spridningsdiagram,
- beräkna korrelationen, och
- beskriva sambandet med ord.

Fundera även på följande fråga: **Betyder korrelation att den ena variabeln orsakar den andra?**

Övning del 4 – Regression

En jordobservationssatellit har varit i drift i över tio år. Ingenjörerna Anne, Marie och Michael vill förstå hur olika delar av satelliten förändras med tiden och behöver hjälp att välja lämpliga matematiska modeller. Deras mätvärden finns i [detta dataset](#).

Nu är det er uppgift att avgöra vilken typ av regression som bäst beskriver utvecklingen.

Undersök följande variabelpar:

1. Solpanelens temperatur och effekt,
2. Brusnivån och tid, och
3. Dataöverföringskapaciteten och tid.

För varje par ska ni:

- plotta mätvärdena i ett spridningsdiagram,
- avgöra om en linjär regression, polynomregression av grad 3 eller en linjäriserad exponentiell regression passar bäst, och
- bedöma modellens lämplighet.

Tips: Ni kan plotta regressionen i samma graf som ert spridningsdiagram genom:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import linregress

x = df["variabel1"]
y = df["variabel2"]

plt.scatter(x, y)
plt.plot(x_line, y_line)

plt.show()
```

där `x_line` ges av:

```
x_line = np.linspace(x.min(), x.max(), n)
```

och `y_line` är modellberoende.

Övning del 5 – Slutsatser

Skriv en kort analys av de två dataseten vi har arbetat med idag på ungefär 5–10 meningar totalt. Analysen ska innehålla:

1. Vilka problem ni hittade i datan.
2. Vilka visualiseringar ni skapade.
3. Vilka samband ni upptäckte.
4. Resultatet från regressionen och korrelationen.
5. Era slutsatser.

Försök skriva som en riktig dataanalytiker snarare än att bara lista siffror.

Övning del 6 – Att göra tydliga grafer

Använd ett av de dataset ni har arbetat med tidigare och skapa ett linjediagram eller spridningsdiagram. Förbättra sedan grafen steg för steg.

Del A – Grundläggande förbättringar

Lägg till:

1. En titel.
2. En etikett på x-axeln.
3. En etikett på y-axeln.
4. Ett rutnät.

Fundera nu på följande fråga: **Är grafen lättare att förstå nu än tidigare?**

Del B – Utforska axlarna

Testa att ändra axelgränserna med:

```
plt.xlim(...)  
plt.ylim(...)
```

Besvara nu följande frågor:

- Hur förändras grafen när ni zoomar in?
- Blir några trender tydligare?
- Kan man få samma data att se väldigt olika ut genom att ändra axlarna?

Del C – Jämför flera variabler

Välj två variabler från datasetet och visa dem i samma figur. Lägg till:

- Olika etiketter (`label`)
- En legend (`legend`)

Besvara nu följande fråga: **Varför är en legend viktig när flera kurvor visas samtidigt?**

Del D – Redovisning

När ni är klara ska ni visa grafen för en annan grupp.

Om de kan förstå vad grafen visar på mindre än 30 sekunder har ni sannolikt lyckats göra den tydlig.