

Föreläsning 2

När data ljuger

Det här är en viktig föreläsning om hur vi ser på data.

Vi går från att behandla data som något objektivt och exakt, till att förstå data som något som alltid är ofullständigt, brusigt och ibland missvisande.

Målet med den här föreläsningen är att ni ska börja se data som en tolkning av verkligheten snarare än verkligheten själv. Ni ska alltså förstå att data inte bara är något man "räknar på", utan något man måste tolka, rensa och ifrågasätta.

Varför data inte är sanningen

Data ser ofta exakt ut på ytan, men under ytan finns många problem som påverkar vad vi faktiskt ser. Några av dessa är:

Varför data inte är sanningen

Data ser ofta exakt ut på ytan, men under ytan finns många problem som påverkar vad vi faktiskt ser. Några av dessa är:

Saknade värden: Saknade värden uppstår naturligt i nästan all riktig data. Frågan är därför inte *om* data saknar värden, utan *hur vi hanterar det*.

Varför data inte är sanningen

Data ser ofta exakt ut på ytan, men under ytan finns många problem som påverkar vad vi faktiskt ser. Några av dessa är:

Saknade värden: Saknade värden uppstår naturligt i nästan all riktig data. Frågan är därför inte *om* data saknar värden, utan *hur vi hanterar det*.

Brus: Även när allt fungerar perfekt finns det små slumpmässiga variationer i mätningar. Detta kallas för brus och gör att data aldrig blir helt stabil.

Varför data inte är sanningen

Data ser ofta exakt ut på ytan, men under ytan finns många problem som påverkar vad vi faktiskt ser. Några av dessa är:

Saknade värden: Saknade värden uppstår naturligt i nästan all riktig data. Frågan är därför inte *om* data saknar värden, utan *hur vi hanterar det*.

Brus: Även när allt fungerar perfekt finns det små slumpmässiga variationer i mätningar. Detta kallas för brus och gör att data aldrig blir helt stabil.

Outliers: Ibland dyker det upp extremt avvikande värden. En central fråga är därför alltid: **Är detta ett fel eller en drastisk förändring?**

I verkliga dataset saknas ofta värden. Det kan bero på flera saker, däribland:

- moln som blockerar satellitbilder,
- sensorfel i mätinstrument,
- kommunikationsfel när data skickas, och
- att en mätning helt enkelt inte gick att genomföra.

Saknade värden är alltså inte ovanliga fel, utan en naturlig del av riktig data.

Vad gör vi med saknade värden?

Vad gör vi med saknade värden?

Vad gör vi med saknade värden?

Vad gör vi med saknade värden?

När man ser saknade värden i ett dataset kan man välja mellan olika strategier:

- ignorera dem,
- ta bort rader, och
- ersätta dem med ett uppskattat värde.

Valet av strategi påverkar resultatet, så jag vill att ni nu funderar på **för- och nackdelar med de olika strategierna.**

Exempel: NDVI

En satellit har mätt vegetationen i ett område under sommaren. Resultatet presenteras i tabellen nedan.

Tabell: Tabellen visar NDVI-indexet i ett område under sommaren.

Datum	NDVI
1 juni	0,62
8 juni	0,64
15 juni	—
22 juni	0,68
29 juni	0,70

Varför tror ni att värdet saknas den 15 juni?

Exempel: NDVI

En möjlig orsak är att området var täckt av moln när satelliten passerade, och att satelliten därför inte kunde mäta marken.

Vad skulle ni göra om ni behövde analysera den här datan? Alltså, hur skulle ni hantera det saknade mätvärdet?

Ibland finns det värden som sticker ut kraftigt från resten av mätvärdena. Några exempel är:

- en extremt hög temperatur en dag,
- en plötslig topp i ljusstyrka, och
- ett mätfel som ger orimliga värden.

En viktig fråga att ställa sig är därför: **Är det ett fel eller en verklig händelse?**

När vi hittar outliers måste vi alltså fundera på följande:

- Är det en felmätning?
- Är det en extrem men verklig händelse?
- Ska vi behålla eller filtrera bort den?

Det finns inget automatiskt rätt svar, utan man får ta det fall till fall.

Exempel: Extrem värmebölja?

En mätstation har mätt temperaturen i Sverige under sommaren och kommit fram resultatet som visas i tabellen nedan.

Tabell: Tabellen visar temperaturen i Sverige under en sommar.

Datum	Temperatur [°C]
1 juli	22
2 juli	23
3 juli	24
4 juli	312
5 juli	25
6 juli	24

Exempel: Extrem värmebölja?

Är det rimligt att temperaturen plötsligt blev 312 grader i Sverige?

Exempel: Extrem värmebölja?

Är det rimligt att temperaturen plötsligt blev 312 grader i Sverige?

Nästan helt säkert är det ett sensorfel. Nu vill jag att ni funderar på **hur ni skulle hantera outliern i detta dataset.**

Exempel: Skogsbränder

En satellit har kartlagt den brända skogsarealen på en viss plats i några år och kommit fram till resultatet som visas i tabellen nedan.

Tabell: Tabellen visar den brända skogsarealen på en viss plats.

År	Bränd skogsareal [km ²]
2018	12
2019	15
2020	14
2021	16
2022	13
2023	89

Exempel: Skogsbränder

Är 89 ett fel?

Exempel: Skogsbränder

Är 89 ett fel?

Kanske inte. Det kan vara ett år med extrema skogsbränder.

Värt att komma ihåg är att alla outliers inte nödvändigtvis är fel, och att de ibland är de mest intressanta datapunkterna i hela datasetet.

Filtrering av data

Ofta vill vi inte analysera hela datasetet, utan bara en del av det. Några exempel på filtrering är:

- bara Sverige,
- bara år 2025,
- bara sommarmånader, och
- ett specifikt område.

Filtrering gör att vi kan fokusera på en mer relevant del av mätvärdena.

Kan ni komma på några exempel på när man vill filtrera data?

Samband mellan variabler

Som vi såg i laboration 1 kan spridningsdiagram används för att undersöka samband mellan två variabler. De hjälper alltså oss att se om det finns ett mönster i mätvärdena.

Varför behövs spridningsdiagram?

Samband mellan variabler

Som vi såg i laboration 1 kan spridningsdiagram används för att undersöka samband mellan två variabler. De hjälper alltså oss att se om det finns ett mönster i mätvärdena.

Varför behövs spridningsdiagram?

Många samband syns inte i tabeller, men blir tydliga när man ritar upp mätvärdena som punkter.

När två variabler verkar följa varandra säger vi att de har en korrelation.

Stark korrelation: En stark korrelation betyder att punkterna i ett spridningsdiagram tydligt följer ett mönster.

Svag korrelation: En svag korrelation betyder att punkterna är mer utspridda och att inget tydligt mönster syns.

Korrelation $\neq$ kausalitet

En av de viktigaste idéerna i hela kursen är: **Att två saker samvarierar betyder inte att den ena orsakar den andra.**

Ett tydligt exempel är att glassförsäljning och drunkningsolyckor ökar samtidigt, men glass orsakar inte drunkning. I stället påverkas båda av en tredje faktor: sommarvärme.

För att mäta hur mycket en variabel varierar kring sitt medelvärde använder vi **varians**.

Population:

$$\text{Var}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Stickprov:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$$

En hög varians innebär att värdena är utspridda, medan en låg varians innebär att de ligger nära medelvärdet.

Varians beskriver hur *en* variabel varierar.

Kovarians, $\text{cov}(x, y)$, beskriver hur *två* variabler varierar tillsammans.
Formeln för kovarians är:

$$\text{cov}(x, y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$

för population, och

$$s_{x,y} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}).$$


för stickprov.

Det finns olika typer av kovarians:

- Positiv kovarians: variablerna tenderar att öka tillsammans.
- Negativ kovarians: när den ena ökar tenderar den andra att minska.
- Kovarians nära 0: inget tydligt linjärt samband.

Kovarians

Figuren nedan konkretiserar positiv och negativ kovarians.



Figur: En konkretisering av positiv och negativ kovarians.

Pearsons korrelation

Det finns olika sätt att beräkna korrelation på. Ett vanligt sätt är:

Pearsons korrelation: Pearsons korrelation bygger på idén om kovarians, det vill säga hur två variabler varierar tillsammans. För två variabler x och y definieras Pearsons korrelation som

$$r = \text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y},$$

där $\text{cov}(x, y)$ är kovariansen mellan variablerna och σ_x , σ_y är standardavvikelserna.

Detta innebär att vi först mäter hur mycket x och y samvarierar, och sedan skalar detta värde så att resultatet alltid hamnar mellan -1 och 1 .

Pearsons korrelation

Formeln kan också skrivas som ett normaliserat medelvärde av produkten av standardiserade värden:

$$r = \frac{1}{n-1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma_x} \right) \left(\frac{y_i - \bar{y}}{\sigma_y} \right),$$

vilket visar att Pearson mäter hur ofta x och y avviker från sina medelvärden i samma riktning.

Spearman's korrelation

Ett annat vanligt sätt är:

Spearman's korrelation: Spearman's korrelation beräknas genom att först ersätta alla värden med deras rang (ordning). Om vi kallar dessa rangvärden $R(x_i)$ och $R(y_i)$, så beräknas Spearman som Pearsons korrelation mellan rangvariablerna:

$$\rho = \text{corr}(R(x), R(y)).$$

Om datasetet enbart innehåller unika värden kan Spearman också skrivas som:

$$\rho = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)},$$

där $d_i = R(x_i) - R(y_i)$ är skillnaden mellan rang och n är antalet mätvärden.

Kendalls korrelation

Kendalls korrelation bygger i stället på parvisa jämförelser. För alla par av observationer (i, j) tittar man på om ordningen i x och y är överensstämmande eller inte.

Om båda ökar eller minskar tillsammans kallas paret *konkordant*, annars *diskordant*. Kendalls tau definieras som:

$$\tau = \frac{C - D}{\frac{1}{2}n(n - 1)}$$

där C är antalet konkordanta par, D är antalet diskordanta par och n är antalet mätvärden. Detta gör måttet direkt kopplat till sannolikheten att två slumpmässigt valda punkter har samma riktning i både variablerna (det vill säga om den punkt som är större i x också är större i y).

Framöver kommer vi huvudsakligen att använda Pearsons korrelation eftersom vi främst är intresserade av linjära samband och linjär regression.

När vi tittar på ett spridningsdiagram kan vi ibland se att två variabler verkar hänga ihop.

Exempelvis kanske vi upptäcker att vegetation tenderar att minska när temperaturen ökar, eller att energianvändning ökar när nattbelysningen ökar. Problemet är att punkterna sällan ligger exakt på en linje.

Kan vi beskriva det övergripande sambandet med en matematisk modell?

När vi tittar på ett spridningsdiagram kan vi ibland se att två variabler verkar hänga ihop.

Exempelvis kanske vi upptäcker att vegetation tenderar att minska när temperaturen ökar, eller att energianvändning ökar när nattbelysningen ökar. Problemet är att punkterna sällan ligger exakt på en linje.

Kan vi beskriva det övergripande sambandet med en matematisk modell?

Det är precis detta regression handlar om.

Den enklaste modellen är en rät linje:

$$y = kx + m,$$

där:

- x är den oberoende variabeln,
- y är den beroende variabeln,
- k beskriver lutningen, och
- m beskriver var linjen skär y-axeln.

Om k är positiv ökar y när x ökar, och om k är negativ minskar y när x ökar.

Hur väljs linjen?


Om vi har många datapunkter finns det oändligt många linjer som skulle kunna ritas. Regression försöker hitta den linje som passar datapunkterna bäst.

Man kan tänka sig att varje punkt har ett avstånd till linjen. Skillnaden mellan punktens verkliga värde och modellens värde kallas residual.

Regression väljer den linje som gör residualerna så små som möjligt totalt sett.

Exempel: Nattbelysning och energianvändning

Antag att vi studerar nattbelysning och energianvändning. Spridningsdiagrammet kanske ser ut så här:



Figur: Ett exempel på ett spridningsdiagram.

Då kanske regressionen ger följande modell: $\text{Energi} = 2,7 \cdot \text{Nattljus} + 45$

När fungerar inte en linjär modell?

Alla samband är inte linjära, och om vi försöker beskriva sådana samband med en rät linje får vi ofta en dålig modell.

Därför är en viktig fråga alltid: **Verkar en rät linje vara en rimlig beskrivning av mätvärdena?**

Exponentiell regression

Alla samband kan inte beskrivas med en rät linje.

Ett vanligt exempel är exponentiella samband, där förändringen inte är konstant utan istället multiplikativ. En typisk modell ser ut som:

$$y = ae^{bx},$$

där:

- a är startvärdet när $x = 0$,
- b beskriver tillväxt- eller avtagandefarten,
- e är basen för den naturliga exponentialfunktionen.

Exponentiell regression

Om $b > 0$ växer funktionen snabbt när x ökar, medan den avtar om $b < 0$. Exponentiella samband är vanliga i till exempel tillväxtprocesser, spridningsförlopp och vissa klimatrelaterade variabler.

Exponentiell regression

För att kunna analysera ett exponentiellt samband använder man ofta en transformation av dataset. Genom att ta den naturliga logaritmen på båda sidor kan modellen skrivas om till ett linjärt samband:

$$\ln(y) = \ln(ae^{bx}) = \ln(a) + bx.$$

Detta gör att vi kan använda samma typ av metod som vid linjär regression, men på de transformerade värdena. Viktigt att notera är att denna metod endast fungerar när $y > 0$.

Polynomregression

I många fall räcker varken linjära eller exponentiella modeller till för att beskriva dataset. Då kan vi istället använda polynom för att fånga mer komplexa samband.

En polynommodell av grad 2 (en andragradskurva) skrivs som:

$$y = ax^2 + bx + c.$$

Här kan kurvan både böja uppåt och nedåt, vilket gör den mer flexibel än en rät linje. Detta är särskilt användbart när mätvärdena har en tydlig krökning eller när förändringstakten inte är konstant.

Generellt kan man använda polynom av högre grad för att få ännu mer flexibla modeller.

Dock gäller det att vara försiktig: ju högre grad, desto större risk att modellen börjar anpassa sig för mycket till enskilda datapunkter istället för det övergripande mönstret.

Detta fenomen kallas för **överanpassning** och innebär att modellen blir bra på den data man har, men sämre på att generalisera till ny data.

Regression är inte sanningen

En regression ger oss en modell av verkligheten. Det betyder inte att modellen är perfekt, eftersom alla modeller bygger på förenklingar. Dock kan regressioner hjälpa oss att:

- beskriva trender,
- jämföra variabler,
- göra prognoser, och
- upptäcka avvikelser.

En viktig fråga att ställa efter att man har tagit fram en regression är alltid: **Är modellen rimlig?**

Dataanalys handlar inte bara om att räkna och rita grafer. Det handlar om att förstå vad data betyder och vilka begränsningar den har. En viktig tanke att ta med sig är att data ger oss mönster, men inte alltid svar.

Det är upp till oss att tolka och ifrågasätta resultaten vi ser.